

Министерство науки и высшего образования Российской Федерации
ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ АВТОНОМНОЕ
ОБРАЗОВАТЕЛЬНОЕ УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ
НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ ИТМО

Лабораторная работа 4

по дисциплине
“Продвинутые методы
оптимизации”

Выполнил: студент
ФИО: Фёдоров Егор
Группа: J3212

Санкт-Петербург
2026

Цель работы

Цель работы - реализовать с нуля небольшие нейронные сети для бинарной классификации и сравнить их на двух синтетических датасетах. В работе проверяется сеть на основе BReLU + Sigmoid и перцептрон с одним скрытым слоем. Для обучения используется функция потерь cross-entropy, мини-батчевый SGD с настраиваемым размером батча и Adam как модификация, объединяющая momentum-подход и RMSProp-нормировку шага.

Главная практическая идея эксперимента состоит в том, чтобы не просто обучить одну модель, а подобрать гиперпараметры по validation-выборке и затем оценить выбранные модели на отложенном test-наборе.

Постановка задачи

По условию лабораторной работы требуется:

1. построить сеть для бинарной классификации на основе BReLU + Sigmoid без нейросетевых фреймворков;
2. реализовать SGD с регулируемым размером батча и Adam-подобную модификацию;
3. сгенерировать два датасета: `make_moons` и `make_classification`;
4. разделить данные на `train`, `validation` и `test` в пропорции 60/20/20;
5. обучить модели по cross-entropy;
6. реализовать перцептрон с одним скрытым слоем и сравнить результаты.

Вся вычислительная логика вынесена в Python-модули: `data.py`, `models.py`, `optimizers.py`, `training.py`, `plots.py` и `experiments.py`. Ноутбук содержит только вызовы этих методов и вывод графиков.

Данные для работы

Использовались два датасета. Первый датасет имеет две координаты и хорошо показывает нелинейную границу классов:

```
X, y = make_moons(n_samples = 400, noise = 0.15, random_state = 467866).
```

Второй датасет имеет пять признаков:

```
X, y = make_classification(n_samples = 200, n_features = 5, n_redundant = 2,  
n_informative = 2, n_clusters_per_class = 2, n_classes = 2, random_state = 467866).
```

Для каждого датасета применялось стратифицированное разбиение 60/20/20, после чего признаки стандартизировались по среднему и стандартному отклонению train-части.

Таблица 1. Размеры выборок после разбиения

Датасет	Размер	Train	Validation	Test
make_moons	400×2	240	80	80
make_classification	200×5	120	40	40




Рис. 1. Датасет make_moons




Рис. 2. Датасет make_classification в PCA-проекции

Модель BReLU + Sigmoid

В работе BReLU трактуется как bounded ReLU:

$$\text{BReLU}(t) = \min(\max(t, 0), 1).$$

Сеть имеет один скрытый слой:

$$Z_1 = XW_1 + b_1, \quad H = \text{BReLU}(Z_1),$$

$$Z_2 = HW_2 + b_2, \quad \hat{y} = \sigma(Z_2), \quad \sigma(t) = \frac{1}{1 + e^{-t}}.$$

Параметры W_1, b_1, W_2, b_2 обучаются методом обратного распространения ошибки. Для функции BReLU производная равна единице внутри интервала $(0, 1)$ и нулю вне этого интервала. В точках 0 и 1 используется численное соглашение с нулевой производной.

Перцептрон с одним скрытым слоем

Вторая модель имеет ту же структуру Dense-Hidden-Sigmoid, но в скрытом слое вместо BReLU используется сигмоидальная активация:

$$H = \sigma(XW_1 + b_1), \quad \hat{y} = \sigma(HW_2 + b_2).$$

Эта модель используется как базовое сравнение с BReLU-вариантом. Благодаря скрытому слою обе модели способны строить нелинейные границы решений, но характер насыщения активаций различается.

Функция потерь и оптимизация

Для всех моделей использовалась бинарная cross-entropy:

$$L(y, \hat{y}) = -\frac{1}{n} \sum_{i=1}^n (y_i \log \hat{y}_i + (1 - y_i) \log(1 - \hat{y}_i)).$$

В коде реализован мини-батчевый SGD с параметром `batch_size`. Также реализованы Momentum, Nesterov, AdaGrad, RMSProp и Adam. В итоговом эксперименте использовался Adam, так как он устойчиво сходил на обоих датасетах:

$$m_t = \beta_1 m_{t-1} + (1 - \beta_1) g_t, \quad v_t = \beta_2 v_{t-1} + (1 - \beta_2) g_t^2, \\ \theta_t = \theta_{t-1} - \alpha \frac{\hat{m}_t}{\sqrt{\hat{v}_t} + \varepsilon}.$$

Таким образом, Adam можно рассматривать как сочетание momentum-оценки направления и RMSProp-нормировки по второму моменту градиента.

Подбор гиперпараметров

Для каждой пары “датасет-модель” перебиралось число нейронов скрытого слоя $h \in \{8, 16, 32\}$. Скорость обучения была равна 0.01, размер батча - 32. Такая сетка выбрана небольшой, потому что данные компактные, а основная цель работы - показать корректную реализацию обучения и процедуру выбора модели. Выбор лучшей конфигурации выполнялся по максимальному validation F1; при равенстве использовалась меньшая validation loss.

Таблица 2. Сводка перебора гиперпараметров

Датасет	Модель	Конф.	max val acc	max val F1	max test acc
make_classification	BReLU + Sigmoid	3	0.950	0.952	0.950
make_classification	Перцептрон с 1 скрытым слоем	3	0.950	0.952	0.950
make_moons	BReLU + Sigmoid	3	1.000	1.000	0.988
make_moons	Перцептрон с 1 скрытым слоем	3	1.000	1.000	0.963

Итоговые результаты

В таблице ниже показаны лучшие конфигурации и метрики на validation/test выборках. Test-метрики не участвовали в выборе модели и использовались только для финальной оценки.

Таблица 3. Лучшие модели по validation-выборке

Датасет	Модель	h	lr	batch	epoch	val acc	val F1	test acc	test F1
make_moons	BReLU + Sigmoid	32	0.010	32	248	1.000	1.000	0.988	0.988
make_moons	Перцептрон с 1 скрытым слоем	32	0.010	32	300	1.000	1.000	0.963	0.964
make_classification	BReLU + Sigmoid	8	0.010	32	81	0.950	0.952	0.950	0.952
make_classification	Перцептрон с 1 скрытым слоем	32	0.010	32	232	0.950	0.952	0.950	0.952

Для `make_moons` лучшая BReLU + Sigmoid модель получила test accuracy 0.988 и test F1 0.988. Перцептрон с одним скрытым слоем на этом же датасете получил test accuracy 0.963 и test F1 0.964. На `make_classification` обе модели показали сопоставимый результат: BReLU + Sigmoid - test accuracy 0.950, test F1 0.952; перцептрон - test accuracy 0.950, test F1 0.952.




Рис. 3. Сравнение test accuracy лучших моделей




Рис. 4. Сравнение test F1-score лучших моделей

Кривые обучения

Кривые loss показывают, что модели сходятся без выраженного переобучения: validation loss в основном убывает вместе с train loss, а ранняя остановка сохраняет параметры с лучшей validation loss.




Рис. 5. Cross-entropy для make_moons, BReLU + Sigmoid




Рис. 6. Cross-entropy для make_moons, перцептрон




Рис. 7. Cross-entropy для make_classification, BReLU + Sigmoid




Рис. 8. Cross-entropy для make_classification, перцептрон

Границы решений

Для двумерного `make_moons` границы решений строятся напрямую в пространстве признаков после стандартизации. Для пятимерного `make_classification` показан срез по первым двум стандартизированным признакам, а остальные признаки фиксируются в нуле, то есть на среднем значении train-выборки.




Рис. 9. Граница решений на make_moons для BReLU + Sigmoid




Рис. 10. Граница решений на make_moons для перцептрона




Рис. 11. Срез границы решений на make_classification для BReLU + Sigmoid




Рис. 12. Срез границы решений на make_classification для перцептрона

Матрицы ошибок

Матрицы ошибок подтверждают, что основные ошибки связаны с ложноположительными ответами для класса 1. На make_moons BReLU + Sigmoid

допустила одну ошибку на test-выборке, а перцептрон - три ошибки. На `make_classification` обе модели ошиблись одинаково: два объекта класса 0 были отнесены к классу 1.




Рис. 13. Матрицы ошибок лучших моделей на test-выборках

Сравнение результатов

Итоговое сравнение показывает следующую картину:

- сеть BReLU + Sigmoid лучше справилась с `make_moons`, где нужна нелинейная граница решений;
- на `make_classification` обе модели дали одинаковую test accuracy и F1, что говорит о достаточности небольшой сети для этого набора данных;
- Adam оказался удобным оптимизатором для обеих архитектур, так как он не потребовал тонкой ручной настройки шага;
- использование validation-выборки позволило отделить подбор гиперпараметров от финальной test-оценки.

Итоговый вывод

В лабораторной работе были реализованы с нуля две нейросетевые модели для бинарной классификации: сеть BReLU + Sigmoid и перцептрон с одним скрытым слоем. Также были реализованы функция потерь cross-entropy, обратное распространение ошибки, мини-батчевое обучение, SGD-семейство оптимизаторов и Adam.

На датасете `make_moons` лучшей оказалась сеть BReLU + Sigmoid с test accuracy 0.988. Она построила более подходящую нелинейную границу и допустила меньше ошибок. На `make_classification` обе модели показали одинаковую test accuracy 0.950. Это означает, что для данного синтетического датасета обе архитектуры имеют достаточную выразительность.

Практический смысл работы состоит в том, что даже простая нейронная сеть должна обучаться не только по train loss. Для честной оценки качества нужно выделять validation-выборку для подбора гиперпараметров и test-выборку для итоговой проверки.